

## 几何体的向量表示

---

已知二维平面上两定点  $A(5, 1)$ ,  $B(2, 3)$ , 给出线段  $AB$  的方程如下:

$$\begin{cases} x_1 = \theta * 5 + (1 - \theta) * 2 \\ x_2 = \theta * 1 + (1 - \theta) * 3 \end{cases}$$

如果将点  $A$  堪称向量  $\vec{a}$ , 点  $B$  看成向量  $\vec{b}$ , 则线段  $AB$  的向量表示为:

$$\vec{x} = \theta \vec{a} + (1 - \theta) * \vec{b}, \quad \theta \in [0, 1]$$

直线的向量表示是

$$\vec{x} = \theta \vec{a} + (1 - \theta) * \vec{b}, \quad \theta \in R$$

故我们可以将类似的想法推广到多维平面

三角形:

$$\vec{x} = \theta_1 \vec{a}_1 + \theta_2 \vec{a}_2 + \theta_3 \vec{a}_3, \quad \theta_i \in [0, 1] \text{ and } \sum \theta_i = 1$$

二维平面:

$$\vec{x} = \theta_1 \vec{a}_1 + \theta_2 \vec{a}_2 + \theta_3 \vec{a}_3, \quad \theta_i \in R \text{ and } \sum \theta_i = 1$$

超几何体的向量表示:

$$\vec{x} = \theta_1 \vec{a}_1 + \theta_2 \vec{a}_2 + \cdots + \theta_k \vec{a}_k, \quad \theta_i \in [0, 1] \text{ and } \sum \theta_i = 1$$

超平面的向量表示:

$$\vec{x} = \theta_1 \vec{a}_1 + \theta_2 \vec{a}_2 + \cdots + \theta_k \vec{a}_k, \quad \theta_i \in R \text{ and } \sum \theta_i = 1$$

## 凸集

---

集合  $C$  内任意两点间的线段也均在集合  $C$  内, 则称集合  $C$  为凸集, 数学定义为:

$$\forall x_1, x_1, \dots, x_k \in C, \theta_i \in [0, 1] \text{ and } \sum \theta_i = 1, \text{ then } x = \sum_{i=1}^k \theta_i x_i \in C$$

上面凸集的定义中使用到了超几何体的向量表示,且凸集的交集仍是凸集.

## 凸函数

---

凸函数定义为:

$$f: C \subseteq R^n \rightarrow R^1, C, x_1, x_2 \in C, :$$

$$f(\alpha_1 x_1 + \alpha_2 x_2) \leq \alpha_1 f(x_1) + \alpha_2 f(x_2) \quad \sum a_i = 1, a_i \geq 0$$

则称  $f(x)$  为定义在凸集  $C$  上的凸函数.

严格凸函数定义为:

$$f: C \subseteq R^n \rightarrow R^1, C, x_1, x_2 \in C, :$$

$$f(\alpha_1 x_1 + \alpha_2 x_2) < \alpha_1 f(x_1) + \alpha_2 f(x_2) \quad \sum a_i = 1, a_i \geq 0$$

则称  $f(x)$  为定义在凸集  $C$  上的严格凸函数.

根据一阶导数判断函数凸性:

设  $f(x)$  为定义在凸集  $R$  上,且为具有连续一阶导数的函数,则  $f(x)$  在  $R$  上为凸函数的充要条件是对凸集  $R$  内任意不同两点,不等式

$$f(x_2) \geq f(x_1) + (x_2 - x_1)^T \nabla f(x_1)$$

恒成立.

根据二阶导数判断函数凸性:

设  $f(x)$  为定义在凸集  $R$  上,且为具有连续二阶导数的函数,则  $f(x)$  在  $R$  上为凸函数的充要条件是 Hesse 矩阵在  $R$  上处处半正定.

几何含义:

函数任意 $A_1, A_2$ 之间的部分位于 $A_1, A_2$ 连线的下方.

## 凸函数优点

---

凸函数的局部极小值是全局极小值.在机器学习中,我们只需要将非凸函数转化为凸函数,便可直接通过梯度下降或者牛顿法得出问题的全局极值.

## 詹森不等式

---

$f(x)$ 为凸函数,其中  $E(x)$ 是  $x$  的期望,我们有

$$f(E(x)) \leq E(f(x))$$

## 无约束优化

---

解决方法就是对变量求导.

## 等式约束优化

---

1. 可以使用消元法,因为是等式,可以代入原式
2. 拉格朗日乘子法